

Bibliographie annotée

Aggregating User Preferences while Ensuring Equity, Diversity, and Inclusion using Graph Summarization

Adji Marieme Sita Cissé — Phase 1 (revue de littérature) — Université de Regina

Axe 1 — Agrégation de préférences & théorie du choix social

Le socle théorique. Tes baselines (Borda, Condorcet, ranked choice) viennent d'ici. L'enjeu : comprendre pourquoi aucune méthode n'est « parfaite » (Arrow), ce qui justifie de raisonner en termes de propriétés préservées plutôt que d'optimum absolu.

Arrow's Impossibility Theorem (à citer via un manuel de social choice)

K. Arrow, Social Choice and Individual Values, 1951 — résultat fondateur

Pourquoi c'est pertinent : C'est LE résultat qui légitime ton approche : aucune fonction d'agrégation ne satisfait simultanément un ensemble de critères d'équité raisonnables. Tu ne cherches donc pas la méthode idéale, mais celle qui préserve le mieux des métriques EDI choisies.

À retenir : À citer en introduction pour cadrer le problème. Ne perds pas de temps sur la preuve ; retiens l'énoncé et ses implications pratiques.

Fairness in Preference Queries: Social Choice Theories Meet Data Management

Roy, Schieber & Talmon, Proceedings of the VLDB Endowment, vol. 17(12), 2024

<https://dl.acm.org/doi/10.14778/3685800.3685841>

Pourquoi c'est pertinent : Tutoriel récent qui fait exactement le pont dont tu as besoin : adapter les méthodes d'agrégation du choix social, recenser comment la fairness y a été traitée, et pointer les limites et directions ouvertes. C'est une carte du territoire pour ton Axe 1.

À retenir : Sers-toi de sa bibliographie comme d'un index : les références qu'il cite (Kemeny, Amer-Yahia et al.) sont tes lectures suivantes. Repère la section « limitations » : c'est là que se nichent les gaps.

Proportional Fairness in Clustering: A Social Choice Perspective

arXiv:2310.18162, 2024

<https://arxiv.org/html/2310.18162v2>

Pourquoi c'est pertinent : Relie directement fairness proportionnelle, clustering (donc regroupement de nœuds = summarization) et choix social. Le concept de fairness proportionnelle et de « core » est un candidat sérieux pour ta métrique d'inclusion (les minorités obtiennent une représentation proportionnelle à leur taille).

À retenir : Note la définition formelle de la fairness proportionnelle ; elle peut devenir l'une de tes métriques d'inclusion sur les communautés détectées.

Axe 2 — Graph Summarization

La technique centrale du projet. Trois familles : agrégation/regroupement (supernœuds via community detection — ce que tu cites), sélection (sampling/sparsification), et compression. Ta contribution : ajouter une contrainte « préserver l'EDI » au critère de résumé.

Graph Summarization Methods and Applications: A Survey

Liu, Safavi, Dighe & Koutra, ACM Computing Surveys, 2018

<https://arxiv.org/pdf/1612.04883>

Pourquoi c'est pertinent : Le survey de référence du domaine. Il pose la taxonomie (graphes statiques/plain, avec attributs, dynamiques) et formalise le problème de résumé. Indispensable pour situer ta méthode et en parler avec le vocabulaire standard.

À retenir : Apprends la formulation formelle du « Problem 1 : Summarization of Static Plain Graphs ». Ton apport sera de modifier sa fonction objectif pour y intégrer les métriques EDI.

A Comprehensive Survey on Graph Summarization with Graph Neural Networks

IEEE Transactions on Artificial Intelligence, 2023

<https://arxiv.org/html/2302.06114>

Pourquoi c'est pertinent : Mise à jour moderne du survey précédent, avec la distinction nette Agrégation (node grouping / edge grouping) vs Sélection (sampling / simplification). Utile si tu veux justifier pourquoi tu choisis le node grouping (communautés) plutôt qu'une autre famille.

À retenir : La section sur l'agrégation par node grouping correspond exactement à ta Phase 3 (community detection + coarsening). Garde la terminologie supernode / superedge.

Awesome Graph Reduction (liste curatée, IJCAI 2024)

Dépôt GitHub Emory-Melody — coarsening, condensation, sparsification, summarization

<https://github.com/Emory-Melody/awesome-graph-reduction>

Pourquoi c'est pertinent : Point d'entrée pratique : une liste à jour et triée des papiers de réduction de graphe. Te fait gagner des semaines de recherche manuelle et te garantit de ne pas rater un travail récent.

À retenir : Parcoure-la une fois, marque 5–6 papiers de coarsening, ajoute-les à Zotero. Ne lis pas tout : sélectionne ce qui touche aux graphes pondérés/bipartis (users–items).

Graph Community Detection from Coarse Measurements (Coarsened Weighted SBM)

AISTATS 2021, arXiv:2102.13135

<https://arxiv.org/pdf/2102.13135>

Pourquoi c'est pertinent : Formalise mathématiquement ce qui arrive aux communautés quand on coarsène un graphe, avec des bornes d'erreur de récupération. C'est exactement la question « qu'est-ce que je perds en résumant ? » — transposable à « est-ce que je perds de l'EDI ? ».

À retenir : Le modèle SBM pondéré est un bon cadre génératif pour tester ta méthode sur des graphes synthétiques avant MovieLens. Retiens l'idée de borne d'erreur : tu pourras définir une borne analogue sur la dégradation EDI.

Axe 3 — EDI : fairness, diversité, inclusion (le pont avec la recommandation)

Le cœur original et le plus délicat. Ton plan mélange trois notions distinctes ; ces références t'aident à les séparer et à choisir des formalisations défendables. C'est ici que se joue ta contribution scientifique.

Fairness in Graph Mining: A Survey

Dong et al., IEEE Transactions on Knowledge and Data Engineering, 2023

<https://dl.acm.org/doi/10.1109/TKDE.2023.3265598>

Pourquoi c'est pertinent : LE survey qui croise tes Axes 2 et 3 : la fairness appliquée spécifiquement aux algorithmes sur graphes. Recense les définitions de fairness (de groupe, individuelle), les sources de biais dans les graphes, et les techniques de mitigation. Probablement ta référence la plus structurante.

À retenir : Adopte sa taxonomie des notions de fairness pour structurer TA section « métriques EDI ». Vérifie quelles définitions ont déjà été appliquées à la summarization (peu, sans doute — voilà ton gap).

Fairness and Diversity in Recommender Systems: A Survey

ACM Transactions on Intelligent Systems and Technology, 2024

<https://dl.acm.org/doi/full/10.1145/3664928>

Pourquoi c'est pertinent : Articule fairness ET diversité — deux de tes trois piliers — et montre leur relation (parfois en tension). Utilise MovieLens avec le genre (côté user) et la popularité (côté item) comme attributs sensibles : un protocole quasiment prêt à réutiliser pour toi.

À retenir : Reprends leur distinction fairness (entre groupes) vs diversité (variété des résultats, ex. ILD - intra-list distance, aggregate diversity). Le couple genre/popularité sur MovieLens est ton protocole expérimental de départ.

New Fairness Metrics for Recommendation that Embrace Differences

Yao & Huang, 2017, arXiv:1706.09838

<https://arxiv.org/pdf/1706.09838>

Pourquoi c'est pertinent : Propose des métriques d'unfairness concrètes et calculables pour le filtrage collaboratif, testées sur MovieLens avec des genres à déséquilibre de genre. Te donne des formules prêtes à implémenter et à reporter.

À retenir : Candidats directs pour tes métriques d'équité. Implémente-les tôt (Phase 4) pour avoir une baseline de mesure même avant ta méthode.

User Fairness in Recommender Systems

arXiv:1807.06349

<https://arxiv.org/pdf/1807.06349>

Pourquoi c'est pertinent : Démontre empiriquement le compromis diversité ↔ équité utilisateur (augmenter la diversité agrégée accroît la disparité entre utilisateurs). C'est le genre de tension que ta méthode EDI devra arbitrer explicitement.

À retenir : Cite-le pour justifier que l'EDI n'est pas un objectif unique mais un équilibre. Tes métriques devront capturer ce trade-off, pas le masquer.

Axe 4 — Social choice + recommandation : l'approche multi-agents (état de l'art proche)

Ce groupe est le travail le plus proche du tien : il combine déjà choix social et fairness en recommandation. Lis-le attentivement pour positionner ta différence — ton angle « summarization de graphe » est, lui, peu exploré.

Dynamic fairness-aware recommendation through multi-agent social choice (SCRUF-D)

Aird, Burke, Mattei et al., *ACM Transactions on Recommender Systems*, 3(2), 2024

<https://arxiv.org/html/2410.04551v1>

Pourquoi c'est pertinent : État de l'art de la fairness multi-parties prenantes via le choix social : des « agents d'équité » votent avec l'utilisateur, et leurs préférences sont agrégées par une règle de vote (Borda, Copeland, RankedPairs...). C'est ton concurrent conceptuel le plus direct.

À retenir : Positionne-toi par contraste : SCRUF-D agrège via re-ranking dynamique ; toi, tu agrèges via une structure de graphe résumée. Articule clairement cette différence dans ton état de l'art — c'est ta justification de nouveauté.

Exploring Social Choice Mechanisms for Recommendation Fairness in SCRUF

Burke et al., *arXiv:2309.08621*

<https://arxiv.org/pdf/2309.08621>

Pourquoi c'est pertinent : Compare empiriquement plusieurs règles de vote (weighted voting, Borda, Copeland, RankedPairs) sur le compromis fairness/accuracy. Te donne un protocole de comparaison de baselines directement réutilisable pour ta Phase 5.

À retenir : Reprends leur design de comparaison de règles de vote comme gabarit pour tes propres baselines (Borda/Condorcet/ranked choice cités dans ton plan).

Synthèse : où se situe ta contribution

À l'intersection des quatre axes, un constat se dégage : la fairness en recommandation est traitée surtout par re-ranking (SCRUF-D) ou par régularisation, et la graph summarization optimise traditionnellement la fidélité structurelle (préserver degrés, communautés, distances) — mais **presque jamais la préservation explicite de métriques EDI**. Ton stage comble ce vide : faire de l'EDI une propriété que le résumé de graphe doit conserver, au même titre que la structure.

Formulation candidate de ta question de recherche : « Étant donné un graphe biparti pondéré de préférences users-items, comment construire un résumé (via détection de communautés et coarsening) qui réduit la taille tout en bornant la dégradation des métriques d'équité, de diversité et d'inclusion, comparé aux règles d'agrégation classiques ? »

Prochaines actions concrètes

1. Créer un compte Zotero et un groupe de bibliothèque pour le stage ; y importer les 11 références ci-dessus (les liens arXiv/ACM s'importent en un clic via le connecteur navigateur Zotero).
2. Lire en priorité les deux surveys clés : « Fairness in Graph Mining » (Axe 3) et « Graph Summarization Methods » (Axe 2).
3. Pour chaque article lu, écrire la phrase « lien avec mon problème » directement dans la note Zotero.

4. En parallèle, valider l'environnement technique (Python, NetworkX, Neo4j) pour ne pas bloquer la Phase 2 de juin.
5. Rédiger un brouillon de 2 pages de l'état de l'art structuré selon les 4 axes — ce sera la base de la section « Related Work » de ton papier.