

Phase 2 — Spécification du Modèle

Agrégation des préférences utilisateurs en garantissant l'Équité, la Diversité
et l'Inclusion par la Résumé de Graphe

Auteurs : Adjil Marieme Sita Cissé | Directeur : Prof. Malek Mouhoub — Université de Regina | Juin 2026

1. Modèle de Graphe de Préférences

1.1 Définition Formelle

Les données de préférences sont représentées sous forme de **graphe biparti pondéré et attribué** :

$$G = (U \cup I, E, w, s)$$

Symbole	Définition
$U = \{u_1, u_2, \dots, u_m\}$	Ensemble des nœuds utilisateurs
$I = \{i_1, i_2, \dots, i_n\}$	Ensemble des nœuds items (ex. films dans MovieLens)
$E \subseteq U \times I$	Ensemble des arêtes — $(u, i) \in E$ si et seulement si u a noté i
$w : E \rightarrow [0,5 ; 5]$	Fonction de poids — $w(u, i)$ = note attribuée par u à i
$s : U \rightarrow \{F, H\}$	Attribut sensible — genre de chaque utilisateur (Femme / Homme)

Propriété clé (biparti) : Aucune arête n'existe entre deux utilisateurs ou entre deux items. Seules les arêtes utilisateur–item existent.

1.2 Choix de l'Attribut Sensible

Attribut retenu : le genre (côté utilisateur)

- Directement lié à la question de recherche : le classement collectif représente-t-il équitablement les utilisatrices et les utilisateurs ?
- Le genre est un champ binaire propre dans MovieLens (100k, 1M), sans pré-traitement nécessaire
- Toutes les métriques de référence (Yao & Huang 2017 ; Leonhardt et al. 2018) utilisent le genre côté utilisateur → comparabilité directe avec la littérature
- **Limite à mentionner dans le mémoire** : l'encodage binaire F/H ne reflète pas la diversité de genre réelle ; c'est un point de départ méthodologique à élargir

1.3 Exemple Jouet

4 utilisateurs, 3 items, attribut de genre :

Utilisateur	Genre	i_1	i_2	i_3
u_1	F	5	2	—
u_2	F	4	—	1
u_3	H	—	5	4
u_4	H	1	—	5

Groupes : $G_F = \{u_1, u_2\}$, $G_H = \{u_3, u_4\}$

2. Du Graphe au Classement Collectif

2.1 Paradigme Retenu

Métriques EDI → ancrées dans les notes (valeurs brutes)

- MovieLens fournit des notes directement ; aucune conversion nécessaire
- Préserve l'intensité des préférences (« j'adore » $\neq$ « bof »)
- Correspond aux métriques de Yao & Huang (2017) disponibles dans la bibliographie

Baselines → utilisent les rangs

- Borda et Condorcet sont des méthodes à rangs par définition
- Permet de comparer « agrégation par notes » vs « agrégation par rangs » — résultat expérimental en soi

2.2 Méthodes d'Agrégation de Référence (baselines)

Méthode	Formule	Problème EDI connu
Score moyen	$\text{score}(i) = (1/ U_i) \times \sum_{u:(u,i) \in E} w(u,i)$	Favorise les items populaires auprès du groupe majoritaire
Borda	$\text{score}_B(i) = \sum_u \text{rang}_u(i)$	Biaisé si les groupes sont de tailles inégales
Condorcet	$i > j \text{ si } \{u : w(u,i) > w(u,j)\} > U /2$	La majorité peut systématiquement écraser la minorité

→ Aucune de ces méthodes ne contrôle explicitement l'EDI pendant l'agrégation — ce manque motive le modèle proposé.

2.3 Exemple Jouet — Agrégation

Score moyen :

- $i_1 : (5 + 4 + 1) / 3 = 3,33$
- $i_2 : (2 + 5) / 2 = 3,50$
- $i_3 : (1 + 4 + 5) / 3 = 3,33$

Classement collectif : $i_2 > i_1 \approx i_3$

Classements par groupe :

- G_F préfère : $i_1 > i_2 > i_3$
- G_H préfère : $i_3 > i_2$ (i_1 mal noté)
- Global : i_2 en tête — semble neutre, mais **i_1 (adoré des femmes) est rétrogradé**

→ Le classement global n'est pas équitable : les préférences des femmes sont sous-représentées.

3. Métriques EDI Formelles

Soit $R = (i_1, \dots, i_k)$ le top-k collectif produit. Soient G_F, G_H les deux groupes.

3.1 E — Équité (entre groupes d'utilisateurs)

$$\text{utilité}_g(R) = (1/|G_g|) \times \sum_{u \in G_g} \sum_{i \in R} w(u, i) / k$$

$$\Delta E = |\text{utilité}_F(R) - \text{utilité}_H(R)|$$

- **Interprétation** : Satisfaction moyenne de chaque groupe vis-à-vis du top-k collectif
- **Cible** : $\Delta E \approx 0$ (les deux groupes sont également satisfaits)
- **Source** : Yao & Huang (2017) — métrique de *value unfairness*

3.2 D — Diversité (variété des items recommandés)

$$\text{ILD}(R) = (2 / k(k-1)) \times \sum_{i \neq j \in R} \text{dist}(i, j)$$

$$\text{dist}(i, j) = 1 - \text{similarité_cosinus}(v_i, v_j)$$

où $v_i \in \mathbb{R}^m$ est le vecteur de notes de l'item i sur l'ensemble des utilisateurs (0 si non noté).

- **Interprétation** : Dissimilarité pairwise moyenne au sein du top-k
- **Cible** : ILD élevé (recommandations variées, pas tous le même genre de films)
- **Paramètre à justifier** : similarité cosinus sur vecteurs de notes — alternative : distance basée sur les genres de films

3.3 I — Inclusion (représentation de la minorité dans les résultats)

$$\text{inclusion_g}(R) = (1/|G_g|) \times \sum_{\{u \in G_g\}} |\{i \in R : w(u,i) \geq \theta\}| / k$$

θ = note minimale considérée comme « pertinente » (ex. $\theta = 4,0$)

$\alpha_g = |G_g| / |U|$ (part de la population du groupe g)

- **Interprétation** : Part des items du top-k jugés pertinents par les membres du groupe g
- **Cible (équité proportionnelle — Kellerhals & Peters 2024)** :

$$\text{inclusion_g}(R) \geq \alpha_g$$

Si les femmes représentent 30 % des utilisateurs, au moins 30 % des items du top-k doivent leur convenir.

Ce critère s'appuie sur la notion de « core » : un groupe de taille α_g mérite au moins α_g de l'outcome collectif.

- **Paramètre à justifier** : choix de θ ($\theta \in \{3,5 ; 4,0\}$ seront comparés expérimentalement)

4. Contribution Proposée : Résumé de Graphe sous Contrainte EDI

4.1 Principe

Lors du *coarsening* du graphe (Phase 3), au lieu de fusionner les nœuds librement pour minimiser l'erreur structurelle, on ajoute une **contrainte de préservation de l'EDI** :

Ne pas fusionner deux supernœuds s_a, s_b si leur fusion provoque :

- une augmentation de ΔE au-delà de ϵ_E , **OU**
- une diminution de $ILD(R)$ au-delà de ϵ_D , **OU**
- une diminution de $\text{inclusion}_F(R)$ au-delà de ϵ_I

4.2 Formulation de l'Objectif (à affiner en Phase 3)

$$\begin{aligned} \min \quad & \text{perte_structurelle}(G, G') && [\text{objectif standard du coarsening}] \\ \text{s.c.} \quad & \Delta E(G') \leq \Delta E(G) + \epsilon_E \\ & ILD(G') \geq ILD(G) - \epsilon_D \\ & \text{inclusion}_F(G') \geq \text{inclusion}_F(G) - \epsilon_I \end{aligned}$$

où G' est le graphe résumé et $\epsilon_E, \epsilon_D, \epsilon_I$ sont les tolérances de dégradation EDI.

4.3 Question de Recherche (formulation candidate)

Étant donné un graphe biparti pondéré de préférences $G = (U \cup I, E, w, s)$, comment construire un résumé G' (via détection de communautés et coarsening) qui réduit la taille tout en bornant la dégradation des métriques d'équité (ΔE), de diversité (ILD) et d'inclusion, comparé aux règles d'agrégation classiques (Borda, Condorcet, score moyen) ?

5. Prochaines Étapes

Phase	Action	Livrable
Phase 2 (Juin)	Valider le modèle sur l'exemple jouet en Python/NetworkX	Modèle vérifié + code des métriques
Phase 3 (Juillet)	Concevoir l'algorithme de coarsening sous contrainte EDI	Description de l'algorithme + complexité
Phase 4 (Août)	Implémenter sur MovieLens 100k	Prototype fonctionnel
Phase 5 (Sept.)	Comparer ΔE , ILD, inclusion vs baselines	Résultats expérimentaux

6. Paramètres Ouverts (à documenter dans le mémoire)

Paramètre	Rôle	Justification nécessaire
θ	Seuil de pertinence pour la métrique d'inclusion	Comparer $\theta \in \{3,5 ; 4,0\}$ expérimentalement
k	Taille du top-k	Valeurs standard : $k \in \{5, 10, 20\}$
$\epsilon_E, \epsilon_D, \epsilon_I$	Tolérances de dégradation EDI	Fixer via mesure baseline sur MovieLens
$\text{dist}(i,j)$	Distance entre items pour l'ILD	Cosinus sur vecteurs de notes vs distance basée sur les genres de films